

Lab 1: จำแนกประเภทและออกแบบการจัดเก็บข้อมูล

ให้นักิิตสามารถจำแนก Raw Data, Structured, Semi-structured และ Unstructured Data

และเลือกวิธีจัดเก็บให้เหมาะสม

โจทย์ มหาวิทยาลัยมีข้อมูลดังต่อไปนี้

แหล่งข้อมูล	ประเภทข้อมูล	รูปแบบไฟล์ / Schema	แหล่งจัดเก็บที่เหมาะสม	เหตุผล
ตารางข้อมูลนิสิต (CSV)	Structured	CSV แบบตารางคอลัมน์คงที่	Relational Database (เช่น MySQL/PostgreSQL)	มีโครงสร้างข้อมูลชัดเจน ต้องเชื่อมโยงกับตารางอื่น
ข้อมูลเซนเซอร์ อุณหภูมิ (JSON)	Semi-structured	JSON: มี key-value และ nested object แต่ schema ยืดหยุ่นเปลี่ยนแปลงได้	NoSQL Document DB (MongoDB) หรือ Data Lake	โครงสร้างไม่ตายตัว ข้อมูลไหลเข้าเร็วและต่อเนื่องจากอุปกรณ์ IoT จำนวนมาก
ภาพจากกล้องวงจรปิด	Unstructured	ไฟล์ภาพ/วิดีโอ (JPEG, PNG, MP4) ไม่มี schema	Object Storage (เช่น S3, MinIO) หรือ Data Lake	เป็นไฟล์ไบนารีขนาดใหญ่ ไม่มีโครงสร้างแถว/คอลัมน์ เหมาะกับการเก็บเป็นไฟล์
ไฟล์ PDF ใบสมัครทุน	Unstructured (มี metadata บางส่วน)	PDF: ข้อความ+ฟอรม์ ผสมกัน	Object Storage + จัดทำ metadata index ในฐานข้อมูล/ Data Lake	เนื้อหาหลักเป็นข้อความหรือภาพสแกน ต้องแยก metadata
Log การเข้าใช้งานระบบ LMS	Semi-structured	Log/Text file หรือ JSON-lines	Data Lake หรือระบบ Log Management (เช่น ELK Stack)	มีโครงสร้างบางส่วน แต่รูปแบบแต่ละบรรทัดอาจไม่ตายตัว 100% และมีปริมาณมาก
ผลการลงทะเบียนเรียน (MySQL)	Structured	ตารางเชิงสัมพันธ์ (student_id, course_id, semester, grade)	Relational Database / Data Warehouse (สำหรับวิเคราะห์ย้อนหลัง)	ข้อมูลมีความสัมพันธ์ชัดเจนระหว่างตาราง ต้องการความถูกต้อง

				(ACID) และใช้ วิเคราะห์เชิงสถิติ
ไฟล์เสียงจากศูนย์รับ แจ้งปัญหา	Unstructured	ไฟล์เสียง (WAV, MP3) ไม่มี schema	Object Storage หรือ Data Lake	ไฟล์ไบนารี ต้องผ่าน กระบวนการ Speech-to-Text ก่อนจึงจะนำไป วิเคราะห์เชิง โครงสร้างได้
ข้อมูลดิบจากเครื่อง อ่านบัตร (ยังไม่ ตรวจสอบ)	Raw Data (กึ่ง โครงสร้าง ยังไม่ผ่าน การตรวจสอบ)	CSV/Log ดิบ อาจมี ค่าว่าง ค่าซ้ำ หรือ error	Data Lake (Raw/Bronze zone) ก่อนทำความสะอาดแล้ว ย้ายเข้า Data Warehouse	ยังไม่ผ่านการ ตรวจสอบคุณภาพ จึงควรเก็บในโซน ข้อมูลดิบก่อน ไม่ควร นำเข้า Data Warehouse โดยตรง

ปัญหาคุณภาพข้อมูล

- Missing device_id: 2 แถว
- Duplicate rows (device_id + timestamp ซ้ำกัน): 25 แถว
- Outlier ของ temp_c (ค่า -999 หรือ 85/67.8 ซึ่งเกินช่วง 0–50°C): 10 แถว
- Outlier ของ battery (ค่าติดลบ หรือเกิน 100 เช่น 999, 115, 108): 5 แถว
- Missing value: temp_c 5 แถว, battery 3 แถว, motion 4 แถว
- รูปแบบ motion ที่ไม่ถูกต้อง/ไม่สม่ำเสมอ: '0', 'yes', 'unknown', 'TRUEE', 'FALSEE' (ต้อง normalize เป็น true/false)

ชื่อคอลัมน์ (Column)	Missing Value (ค่าสูญหาย)	Duplicate (แถว ซ้ำ)*	Error (ข้อมูล ผิดพลาดทาง กายภาพ/ ฟอร์แมต)	Outlier (ค่าที่สูง/ ต่ำกว่าปกติ มาก)
timestamp	0	25	0	0
device_id	2	25	0	0

temp_c (อุณหภูมิ)	7	25	6 (พบค่า -999.0 ซึ่งเป็นค่า Error ของเซนเซอร์)	4 (พบค่า อุณหภูมิสูง ผิดปกติ 67.8°C และ 85.0°C สาม ครั้ง)
motion (การตรวจจับ)	4	25	5 (พบฟอร์แมต ผิดปกติ: '0', 'yes', 'unknown', 'TRUEE', 'FALSEE')	0
battery (แบตเตอรี่)	4	25	5 (ค่าติดลบ -5, -1, ค่าเกินจริง 999, และค่ามากกว่าร้อยละ 108, 115)	0
รวม (Total)	17	25	16	4

เปรียบเทียบจำนวนแถวก่อนและหลังทำความสะอาด

Initial number of rows (raw data): 480

Final number of rows (cleaned data): 453

Total rows removed during cleaning: 27

อธิบายว่าทำไมจึงไม่ควรลบ Raw Data ต้นฉบับ

- การตรวจสอบย้อนกลับ
- การทำซ้ำ
- การพัฒนาและปรับปรุงกฎเกณฑ์คุณภาพข้อมูลในอนาคต
- การเปรียบเทียบประสิทธิภาพการทำความสะอาด